动机。通义新论文SeeUPO在Agent相关基准上获得了20个百分点的提升。但是，(1) 若能进一步完成偏差与方差的理论分析，能更好的理解与现有方法的关系；(2) 若能实现异步RL框架下的SeeUPO，在训练效率和适用性上会更好。

一、SeeUPO的偏差与方差分析(本人贡献)

结论：SeeUPO可被视作**采用逆序更新的H-GSPO**。H-GSPO本身已经在GSPO的基础上对长度偏差与方差进行了权衡，而逆序更新的引入则进一步在动态训练中抑制了方差。

> 注：H-GSPO是本人为了更清晰地说明证明过程而引入的一个中间算法概念。

1. 什么是H-GSPO?

1.1 GRPO

在不考虑裁剪的情况下，给定prompt x，从策略$\pi_{\theta_{old}}$采样G个response，GRPO的目标函数是

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{x\sim D,\{y_i\}_{i=1}^{G}\sim\pi_{\theta_{old}}(\cdot|x)}\left[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|y_i|}\sum_{t=1}^{|y_i|}r_{i,t}(\theta)\hat{A}_i\right] \tag{1}$$

其中$r_{i,t}(\theta) = \frac{\pi_\theta(y_t|x,y_{<t})}{\pi_{\theta_{old}}(y_t|x,y_{<t})}$是重要性采样，$\hat{A}_i$是优势。

1.2 GSPO

GSPO认为GRPO的token级重要性采样方差太高，因此用几何平均值构建序列级重要性采样

$$J_{\text{GSPO}}(\theta) = \mathbb{E}_{x\sim D,\{y_i\}_{i=1}^{G}\sim\pi_{\theta_{old}}(\cdot|x)}\left[\frac{1}{G}\sum_{i=1}^{G}s_i^{\text{GSPO}}(\theta)\hat{A}_i\right] \tag{2}$$

其中

$$r_i^{\text{GSPO}}(\theta) = \left(\prod_{t=1}^{|y_i|}r_{i,t}(\theta)\right)^{\frac{1}{|y_i|}} = \exp\left(\frac{1}{|y_i|}\sum_{t=1}^{|y_i|}\log r_{i,t}(\theta)\right) \tag{3}$$

1.3 H-GSPO

在多轮agentic rl训练中，每一轮采用GSPO的方法计算重要性采样，轮次之间则是标准重要性采样计算方式，这种方式称为H-GSPO。形式化定义：将完整的轨迹划分为总共K个轮次，第k个轮次s_k的长度为T_k，那么整个序列的重要性采样为

$$r_i^{\text{H-GSPO}}(\theta) = \prod_{k=1}^{K}\left(\frac{\pi_\theta(s_k)}{\pi_{\theta_{old}}(s_k)}\right)^{1/T_k} \tag{4}$$

这里$\frac{\pi_\theta(s_k)}{\pi_{\theta_{old}}(s_k)}$是轮次片段$s_k$中所有token重要性采样的乘积。下图是一个更直观的理解，

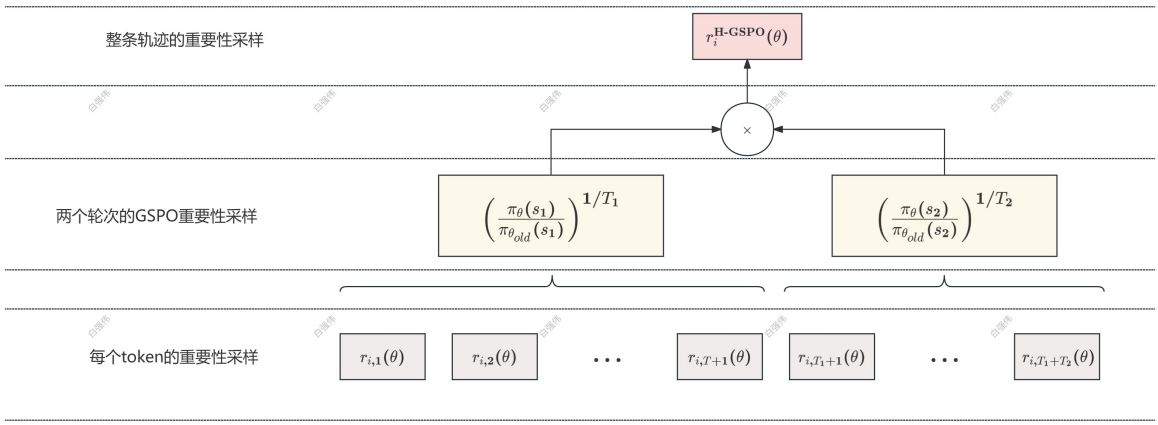

2. H-GSPO缓解了GSPO的长度偏差

为了符号简洁，用τ表示完整的轨迹，采用直接相乘得到的轨迹重要性采样为

$$W(\tau) = \frac{\pi(\tau)}{\mu(\tau)} = \prod_{t=1}^{T} \frac{\pi(y_t|x, y_{<t})}{\mu(y_t|x, y_{<t})} \tag{5}$$

其中π是目标策略，μ是行为策略。

2.1 GSPO的长度偏差

结论：GSPO存在长度偏差，随着轨迹长度的增长会逐步偏离目标策略π。

这里采用VESPO中的证明。GSPO的梯度进行变换有，

$$\begin{aligned}\nabla_\theta J_{\text{GSPO}} &= \mathbb{E}_{\tau\sim\mu}\left[W(\tau)^{1/T} \cdot A(\tau)\nabla \log \pi\right] \\ &= \int u(\tau) W(\tau)^{1/T} \cdot A(\tau)\nabla \log \pi \, d\tau \\ &= \mathbb{E}_{\tau\sim Q(\tau)} Z \cdot A(\tau)\nabla \log \pi\end{aligned} \tag{6}$$

其中$Q_{\text{GSPO}}(\tau) = \frac{1}{Z}\mu(\tau)W(\tau)^{1/T}$，$Z = \mathbb{E}_{\tau\sim\mu}[W^{1/T}]$是归一化因子使得$\int Q_{\text{GSPO}}(\tau)\, d\tau = 1$。因此，GSPO本质是在优化隐式分布$Q_{\text{GSPO}}(\tau)$。对$Q_{\text{GSPO}}(\tau)$进行变化有

$$\begin{aligned}Q_{\text{GSPO}}(\tau) &\propto \mu(\tau)W(\tau)^{1/T} \\ &\propto \mu(\tau)\frac{\pi(\tau)^{1/T}}{\mu(\tau)^{1/T}} \\ &\propto \mu(\tau)^{1-1/T} \cdot \pi(\tau)^{1/T}\end{aligned} \tag{7}$$

当轨迹长度$T = 1$时有$Q_{\text{GSPO}}(\tau) \propto \pi(\tau)$，此时无偏差。

当轨迹长度$T \to \infty$时有$\lim_{T\to\infty} Q_{\text{GSPO}}(\tau) \propto \mu(\tau)^1 \cdot \pi(\tau)^0 = \mu(\tau)$，优化策略退回行为策略$\mu$。

2.2 H-GSPO的长度偏差

长度为T的轨迹τ共包含K个轮次，即$\tau = (s_1, s_2, \ldots, s_K)$。每个轮次的长度为$T_k$，则$T = \sum_{k=1}^{K} T_k$。采用H-GSPO的重要性采样方式则有

$$W_{\text{H-GSPO}}(\tau) = \prod_{k=1}^{K}\left(\frac{\pi(s_k)}{\mu(s_k)}\right)^{1/T_k} \tag{8}$$

那么H-GSPO的隐式分布为

$$
\begin{aligned}
Q_{\text{H-GSPO}}(\tau) &\propto \mu(\tau) \cdot W_{\text{H-GSPO}}(\tau) \\
&= \left(\prod_{k=1}^{K} \mu(s_k)\right) \cdot \left(\prod_{k=1}^{K} \left(\frac{\pi(s_k)}{\mu(s_k)}\right)^{1/T_k}\right) \\
&= \prod_{k=1}^{K} \left[\mu(s_k) \cdot \mu(s_k)^{1-1/T_k} \cdot \pi(s_k)^{1/T_k}\right] \\
&= \prod_{k=1}^{K} \mu(s_k)^{1-1/T_k} \cdot \pi(s_k)^{1/T_k}
\end{aligned} \tag{9}
$$

2.3 二者长度偏差的对比

我们按分段的符号重新整理GSPO和H-GSPO隐式分布的表达式，如下

$$
\begin{aligned}
Q_{\text{GSPO}}(\tau) &\propto \prod_{k=1}^{K} \left(\mu(s_k)^{1-1/T} \cdot \pi(s_k)^{1/T}\right) \\
Q_{\text{H-GSPO}}(\tau) &\propto \prod_{k=1}^{K} \left(\mu(s_k)^{1-1/T_k} \cdot \pi(s_k)^{1/T_k}\right)
\end{aligned} \tag{10}
$$

由于$\frac{1}{T_k} > \frac{1}{T}$，H-GSPO在目标策略$\pi$上的权重远大于GSPO，即$Q_{\text{H-GSPO}}$比$Q_{\text{GSPO}}$更接近目标分布$\pi$。因此，H-GSPO能够缓解GSPO本身的长度偏差。

2.4 极端情况分析

每个token即是一个轮次。即$K = T$且$T_k = 1$，H-GSPO退化为直接token重要性相乘的方式。

只有一个轮次。即$K = 1, T_1 = T$，H-GSPO退化为标准的GSPO。

3. H-GSPO的方差分析

假设每个token的对数重要性采样比率为$X_t = \log \frac{\pi(y_t)}{\mu(y_t)}$，$X_t$是独立同分布且方差为$\text{Var}(X_t) = \sigma^2$。

3.1 token重要性采样直接相乘的方差

$$
\text{Var}(\log W(\tau)) = \text{Var}(\sum_{t=1}^{T} X_t) = T \cdot \sigma^2 \tag{11}
$$

随着长度增加，方差快速增长。

3.2 GSPO的方差

$$
\begin{aligned}
\text{Var}(\log W(\tau)^{1/T}) &= \text{Var}(\frac{1}{T} \sum_{t=1}^{T} X_t) \\
&= \frac{1}{T^2} \sum_{t=1}^{T} \text{Var}(X_t) = \frac{\sigma^2}{T}
\end{aligned} \tag{12}
$$

标准GSPO的方差与总长度T成反比，当T太大时，方差趋近于0。这会导致在长轨迹无有效的学习信号。

3.3 H-GSPO的方差

$$
\begin{aligned}
\mathrm{Var}(\log W_{\text{H-GSPO}}(\tau)) &= \mathrm{Var}\left(\log \prod_{k=1}^{K}\left(\frac{\pi(s_k)}{\mu(s_k)}\right)^{1/T_k}\right) \\
&= \mathrm{Var}\left(\sum_{k=1}^{K}\frac{1}{T_k}\sum_{t\in s_k}X_t\right) \\
&= \sum_{k=1}^{K}\frac{1}{T_k^2}\cdot T_k\cdot\sigma^2 \\
&= \sigma^2\sum_{k=1}^{K}\frac{1}{T_k}
\end{aligned}
\tag{13}
$$

3.4 方差之间的关系

结论一：H-GSPO方差大于GSPO的K^2倍。

证明：构建柯西不等式，

$$
\left(\sum_{k=1}^{K}\frac{1}{T_k}\right)\left(\sum_{k=1}^{K}T_k\right) \geq \left(\sum_{k=1}^{K}\frac{1}{\sqrt{T_k}}\cdot\sqrt{T_k}\right)^2
$$

$$
\left(\sum_{k=1}^{K}\frac{1}{T_k}\right)\cdot T \geq \left(\sum_{k=1}^{K}1\right)^2 = K^2
$$

两边同时除以T，有

$$
\sum_{k=1}^{K}\frac{1}{T_k} \geq \frac{K^2}{T}
$$

最终H-GSPO与GSPO的关系为

$$
\mathrm{Var}(\log W_{\text{H-GSPO}}) \geq K^2\cdot(\frac{\sigma^2}{T}) = K^2\cdot\mathrm{Var}(\log W(\tau)^{1/T}) \tag{14}
$$

结论二：H-GSPO的方差小于直接相乘。

$$
\mathrm{Var}(\log W_{\text{H-GSPO}}(\tau)) = \sigma^2\sum_{k=1}^{K}\frac{1}{T_k} \leq K\sigma^2 \leq T\sigma^2 \tag{15}
$$

4. H-GSPO的阶段性总结

H-GSPO的长度偏差与方差均介于直接相乘法和GSPO之间。

5. SeeUPO：引入逆序更新的H-GSPO

在传统方法中，一条包含K轮对话的完整轨迹τ通常仅在单次batch中完整地参与一次模型更新。SeeUPO引入逆序更新机制，可以被视作一种带有时间依赖的H-GSPO。

具体来说，对于同一条多轮轨迹，模型会按照从后向前的顺序将其利用K次：优先优化第K轮的策略，再优化第$K-1$轮，依次类推，直至退回第1轮。在更新第i轮时，模型将原始prompt与前$i-1$轮的对话历史拼接为context，将第i轮的对话作为target进行强化学习。

在优化第i轮策略时，只需要考虑从当前轮次i到最终轮次K的重要性采样。因此，对于第i轮更新，H-GSPO的重要性采样比率调整为

$$W^i_{\text{H-GSPO}}(\tau) = \prod_{k=i}^{K} \left(\frac{\pi(s_k)}{\mu(s_k)} \right)^{1/T_k} \tag{16}$$

6. 基于课程学习的动态方差缩减

上面对H-GSPO的方差分析是在静态的、单一batch假设下进行的，即假设每个token的方差恒定为σ^2。SeeUPO则跨越多个更新步，在**长期的动态训练中**实现了更深层次的方差控制。

逆序更新的本质是由易到难的课程学习。在一个多轮对话轨迹中，越靠后的轮次，模型接收到的上下文历史信息越丰富。充分的上下文使得动作空间的不确定性下降，策略更容易拟合目标分布。相反，早期轮次面临的高度开放的生成任务，拟合难度最大。因此，从第K轮向第1轮的逆序更新，本质上是在单条轨迹上构建了一条由易到难的课程学习路径。

长期训练下的方差动态缩减。在课程学习的视角下，容易任务(后置轮次)会先于困难任务(前置轮次)收敛。当策略$\pi(s_k)$在第k轮逐渐收敛时，其输出分布高度贴合目标分布，此时s_k中任意token的对数重要性采样比率$X_t = \log \frac{\pi(y_t)}{\mu(y_t)}$将趋近于0，方差也会随之急剧下降。假设在当前训练阶段，第k轮输出的方差是σ_k^2。由于逆序更新使得后置轮次更早收敛，在优化第i轮时，后续轮次的方差必然严格满足递减关系：

$$\sigma_i^2 > \sigma_{i+1}^2 > \sigma_{i+2}^2 > \cdots > \sigma_K^2 \approx 0 \tag{17}$$

那么按逆序更新的H-GSPO，在第i轮更新时的对数方差为

$$\begin{aligned}
\mathrm{Var}(\log W^i_{\text{H-GSPO}}(\tau)) &= \mathrm{Var}\left(\sum_{k=i}^{K} \frac{1}{T_k} \sum_{t \in s_k} X_t \right) \\
&= \sum_{k=i}^{K} \frac{1}{T_k} \sigma_k^2 \\
&= \frac{\sigma_i^2}{T_i} + \underbrace{\frac{\sigma_{i+1}^2}{T_{i+1}} + \cdots + \frac{\sigma_K^2}{T_K}}_{\text{后续轮次已收敛，该部分趋近于}0} \\
&\approx \frac{\sigma_i^2}{T_i}
\end{aligned} \tag{18}$$

上式清晰的表明，逆序更新阻断了重要性采样方差在长序列上的累积。

因此，在理想情况下，整个长序列的方差被坍缩到了仅受当前轮次T_i控制的极小范围内。

二、异步RL框架下的实现(本人贡献，进行中)

1. 同步框架下的局限性

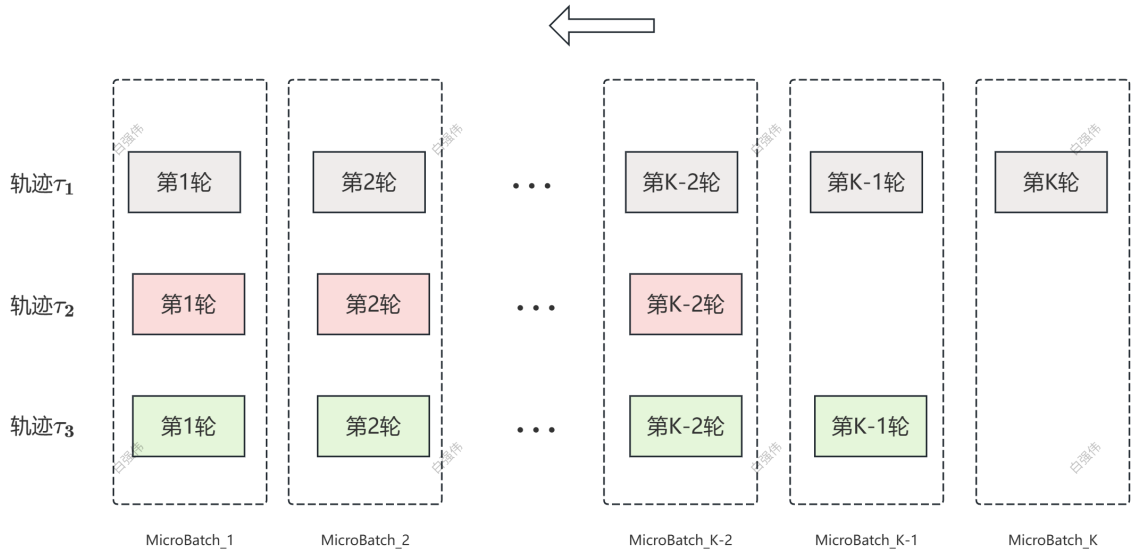

原始论文中使用同步框架实现SeeUPO。简单来说：**1次rollout，K次训练。**

首先，先rollout一次获得一批轨迹，所有轨迹中轮次最多为K。然后，用最后一轮的数据构建一个$\mathrm{MircoBatch}_K$，用倒数第二轮的数据构建一个$\mathrm{MicroBatch}_{K-1}$，依次构建直至$\mathrm{MicroBatch}_1$。最后，按照逆序$K \to K-1 \to \cdots \to 1$使用这些数据对策略模型训练$K$次。

单步时间1.5x的原因分析。论文中指出单步训练时间仅是GSPO/GRPO的1.5倍。训练的次数增加了K倍，但单步仅增加1.5倍，分析原因可能是：(1) 论文将最大轮数限制为10，实际平均轮数应该更低；(2) 同步框架中rollout时间是主要瓶颈，训练时间的增加对单步时间的影响不大。

同步框架实现的问题：

- rollout长尾问题：同步框架的老问题了，训练要等最长的轨迹生成完。
- 样本稀释与GPU利用率：若训练中有少数轮次特别多的轨迹，那么在早期的训练中很可能只有非常少量的样本真正参与训练。某种程度上导致早期训练的轮次batch size减小，**这即可能影响效果，也会导致GPU利用率低。**

2. 异步框架下的实现逻辑

异步RL框架：将训练和推理解耦为两个独立的服务，二者通过消息队列进行通信。此外，通过训练和推理模型版本号的方式控制陈旧度。

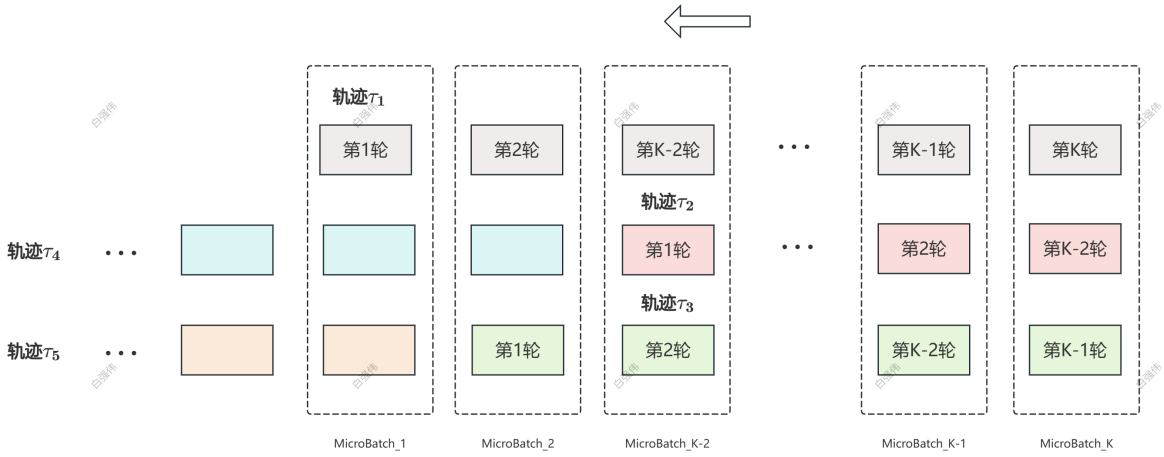

从左对齐调整为右对齐，气泡的部分用新轨迹填充。如上图所示，训练服务在遇到气泡后，直接从消息队列去轨迹进行填充即可。这种方式从理论上仍然保证了每条轨迹仍然是按逆序进行更新的。**但是，这里有一个风险点，需要实验验证**：同步框架中，训练的最好一步具有统一的语义，即给定prompt，然后预测一段对话。而异步实现时，无法找到这样一个语义完全对齐的位置，这也许会影响后续的rollout效果。

三、原始论文解读(非本人贡献)

通义新论文SeeUPO在理论上证明了当前的无Critic方法在多轮场景下无法保证收敛。因此，提出了一种多轮训练的逆序更新机制，利用反向归纳的能力来保证全局最优。

1. 多轮对话重构为多Agent Bandit问题

SeeUPO尝试将多轮任务建模为按序列执行的多agent contextual bandit问题。具体来说，将执行第$t \in 1, 2, \ldots, T$论生成的策略看做是一个独立的agent。这样，T轮输出可以看作是T个不同的agent顺序执行产生的，只不过这些agent共享相同的参数。对于每个单轮任务，则建模为bandit问题。

所有的agent共享全局状态$s_0 \in \mathcal{S}_S$，序列级动作$a^t \in \mathcal{A}_S$代表第t个agent在第t轮的完整响应。全部的动作序列$a^{1:T} = (a^1, a^2, \ldots, a^T)$可以看作所有agent动作的拼接。第$t$个agent的策略表示为$\pi^t(a^t|s_0, a^{1:t-1})$，其输入是全局状态$s_0$和之前所有agent的动作历史$a^{1:t-1}$。奖励采用共享奖励的方式$r(s_0, a^{1:T})$，整个agent team的奖励就是任务最终的奖励。

2. 逆向更新机制

SeeUPO采用了HAML框架的序列更新机制，更新顺序为逆序，即$T \to T-1 \to \cdots \to 1$。这种方式即能解决agent级别更新的冲突，也能保证反向归纳的全局最优。总的来说，当前第$k+1$个batch在第t轮的更新为

$$\hat{\pi}_{k+1}^t = \underset{\bar{\pi}^t \in \mathcal{U}_{\hat{\pi}_k^t}(\hat{\pi}_k^t)}{\arg\max} \quad \mathbb{E}_{s_0 \sim \beta_{\hat{\pi}_k}} \left[\mathbb{E}_{a^{t+1:T} \sim \hat{\pi}_{k+1}^{t+1:T}, a^t \sim \bar{\pi}^t} \left[A_{\hat{\pi}_k}^t(s_0, a^t, a^{t+1:T}) \right] - \mathfrak{D}_{\hat{\pi}_k^t}(\bar{\pi}^t | s_0, \hat{\pi}_{k+1}^{t+1:T}) \right] \tag{1}$$

$\bar{\pi}^t \in \mathcal{U}_{\hat{\pi}_k^t}(\hat{\pi}_k^t)$这个表示当前策略的优化区间位于上一个batch优化策略的附近，实际实现中就是由clip机制保证的。$\mathfrak{D}_{\hat{\pi}_k^t}(\bar{\pi}^t | s_0, \hat{\pi}_{k+1}^{t+1:T})$这个是KL散度约束更新幅度。这个公式的含义是：当前第t轮优化开始之前，已有$t+1:T$个版本的策略。那么，从$T-t$个策略中采样$T-t$个动作$a^{t+1:T}$，再从当前策略中采样动作a^t。然后，最大化轨迹$a^{t:T}$的优势。

3. 局部优势计算

显然，依据公式(1)进行优化的话。每一轮训练，都需要已经更新的策略重新采样。这即需要保存不同版本的模型参数，也需要重新进行采样，代价太高。那么，能不能利用上一个batch更新的策略$\hat{\pi}_k$进行采样，然后利用重要性采样进行调整呢?

$$\begin{aligned} &\mathbb{E}_{a^{t+1:T} \sim \hat{\pi}_{k+1}^{t+1:T}, a^t \sim \bar{\pi}^t} \left[A_{\hat{\pi}_k}^t(s_0, a^t, a^{t+1:T}) \right] \\ &= \mathbb{E}_{a^{1:T} \sim \hat{\pi}_k} \left[\left(\frac{\bar{\pi}^t(a^t|s_0, a^{1:t-1})}{\hat{\pi}_k^t(a^t|s_0, a^{1:t-1})} - 1 \right) \cdot \frac{\hat{\pi}_{k+1}^{t+1:T}(a^{t+1:T}|s_0, a^{1:t})}{\hat{\pi}_k^{t+1:T}(a^{t+1:T}|s_0, a^{1:t})} \cdot \hat{A}_{\hat{\pi}_k}(s_0, a^{1:T}) \right] \end{aligned} \tag{2}$$

右侧乘积第二项展开为$\frac{\hat{\pi}_{k+1}^{t+1:T}(a^{t+1:T}|s_0, a^{1:t})}{\hat{\pi}_k^{t+1:T}(a^{t+1:T}|s_0, a^{1:t})} = \prod_{j=t+1}^{T} \frac{\hat{\pi}_{k+1}^j(a^j|s_0, a^{1:j-1})}{\hat{\pi}_k^j(a^j|s_0, a^{1:j-1})}$，这里利用重要性采样来调整采样分布$\hat{\pi}_k$和$\hat{\pi}_{k+1}$。当然，第二项表面的含义是需要上一个batch的T-t个策略，以及当前batch的$T-t$个策略来计算。但是，得益于反向更新的规则和共享参数，可以认为上一个batch更新完后的$\hat{\pi}_k$能够同时扮演所有轮次的独立策略。**当然，这个假设的成立是当前轮次的更新不会影响已经更新轮次的效果。**对

于右侧乘积第一项$\frac{\bar{\pi}^t(a^t|s_0,a^{1:t-1})}{\hat{\pi}_k^t(a^t|s_0,a^{1:t-1})}-1$，将其拆开与括号外的项相乘，**可以看到是当前轮次的优势减去已经更新轮次的优势，即保证这个优势就是仅评估当前轮次的优势。**

在具体实现中，当$\hat{\pi}_k^t$采样轨迹$a^{1:T}$即得到了所有重要性采样的分母。重要性采样的分子则在前面几轮的更新中都会有结果，保存下来即可。

4. 全局优势计算

全局优势计算直接采用GRPO的方式，即

$$\hat{A}_{\hat{\pi}_k}(s_0,a^{1:T})=r(s_0,a^{1:T})-\mathbb{E}_{a'^{1:T}\sim\hat{\pi}_k(\cdot|s_0)}[r(s_0,a'^{1:T})] \tag{3}$$

5. 具体实现

a. 利用当前的策略$\hat{\pi}_k$采样数据集$\mathcal{D}^k=\{(s_0,a^{1:T},r)\}$，保留轨迹的概率，后续要用于重要性采样。

b. 按轮次重新组织数据集$\mathcal{D}_t^k=\{(s_0,a^{1:t},a^t)\}$。

c. 计算全局优势：$\hat{A}_{\hat{\pi}_k}(s_0,a^{1:T})=r(s_0,a^{1:T})-\bar{r}(s_0)$。

d. 初始化矩阵$M^{T+1}(s_0,a^{1:T})=\hat{A}_{\hat{\pi}_k}(s_0,a^{1:T})$。

e. 从后向前进行策略更新$t=T,T-1,\ldots,1$。策略更新的目标函数为

$$\mathbb{E}_{(s_0,a^{1:t-1},a^t)\sim\mathcal{D}_t^k}\left[\min\left(r^t(\theta)M^{t+1}(s_0,a^{1:T}),\mathrm{clip}(r^t(\theta),1\pm\varepsilon)M^{t+1}(s_0,a^{1:T})\right)\right] \tag{4}$$

M^t的更新策略为

$$M^t(s_t,a^{1:T})=\frac{\pi_{\theta_{k+1}^t}(a^t|s_0,a^{1:t-1})}{\pi_{\theta_k}(a^t|s_0,a^{1:t-1})}\cdot M^{t+1}(s_0,a^{1:T}) \tag{5}$$

这里M^t就是公式(2)右侧乘积的第2项。

一个更直观的理解。对于多轮输出，模型很难通过一次前后向传播学会。逆序更新的话，相当于用prompt和$t-1$轮的输出作为模型的输入，模型仅需要预测第t轮的输出结果即可。**本质上就是对同一条轨迹进行从易到难的课程学习。**

6. 效果

Table 2: Performance comparison on two benchmark environments. Columns show *avg@4* and *pass@4* for each benchmark, plus their averages (Avg.). All values are in percent (%). **Bolded numbers** highlight the best results. Improvement percentages (shown as blue superscripts) indicate SeeUPO's relative improvement over each baseline.

Model & Method	AppWorld		BFCL v4		Avg.	
	avg@4	pass@4	avg@4	pass@4	avg@4	pass@4
Qwen2.5-14B	4.825	7.018	25.50	35.75	15.16	21.39
+PPO	40.79$^{+24.7\%}$	57.89$^{+21.2\%}$	44.75$^{+23.5\%}$	56.00$^{+1.8\%}$	42.77$^{+24.1\%}$	56.95$^{+11.7\%}$
+GRPO	35.53$^{+43.3\%}$	49.12$^{+42.9\%}$	46.25$^{+19.5\%}$	55.00$^{+3.6\%}$	40.89$^{+29.8\%}$	52.06$^{+22.1\%}$
+GSPO	24.12$^{+111.0\%}$	38.60$^{+81.8\%}$	50.75$^{+8.9\%}$	56.00$^{+1.8\%}$	37.44$^{+41.9\%}$	47.30$^{+34.4\%}$
SeeUPO (ours)	**50.88**	**70.18**	**55.25**	**57.00**	**53.07**	**63.59**
Qwen3-14B	20.18	35.09	40.25	47.00	30.22	41.05
+PPO	35.09$^{+81.2\%}$	54.39$^{+48.4\%}$	43.75$^{+32.6\%}$	52.00$^{+25.0\%}$	39.42$^{+54.3\%}$	53.20$^{+36.9\%}$
+GRPO	40.35$^{+57.6\%}$	57.89$^{+39.4\%}$	44.50$^{+30.3\%}$	53.00$^{+22.6\%}$	42.43$^{+43.3\%}$	55.45$^{+31.4\%}$
+GSPO	32.89$^{+93.4\%}$	52.63$^{+53.3\%}$	45.75$^{+26.8\%}$	55.00$^{+18.2\%}$	39.32$^{+54.6\%}$	53.82$^{+35.4\%}$
SeeUPO (ours)	**63.60**	**80.70**	**58.00**	**65.00**	**60.80**	**72.85**