动机：LLM对于同一个prompt，通常会给出较为相似的response。这在强化学习场景下，代表这rollout的轨迹缺乏多样性，探索不足。因此，是否可以引入外部信息进行探索的引导？

本人贡献：设计了一种利用外部模型引导强化学习探索过程的方法，在1.5B模型上有一定效果。

一、整体思路

设当前策略模型为π_θ，外部引导策略模型为π_e。

1. 从π_θ中采样的轨迹中筛选一部分失败的轨迹，作为**候选轨迹**；
2. 基于轨迹的token熵和全局训练状态，挑选一个轨迹切分点，将其划分后前、后两个部分；
3. 丢弃失败轨迹的后半部分，由外部策略模型π_e完成轨迹补全；
4. 将这种嵌合了来自两个不同策略的轨迹添加到batch中进行训练；

二、构造嵌合轨迹

当前策略π_θ采样到的失败轨迹为$y=(y_1,y_2,\ldots,y_L)$，L是失败轨迹的长度。按照某种方式确定一个切分点$t_{\text{split}}\in\{1,\ldots,T\}$，得到前半部分轨迹$y_{<t_{split}}$。将原始prompt x和前半部分轨迹作为输出构建嵌合轨迹

$$y'_{\geq t_{\text{split}}}\sim\pi_e(\cdot|x,y_{t_{\text{split}}})$$
$$y_c=y_{t_{\text{split}}}\circ y'_{\geq t_{\text{split}}}$$

符号$\circ$代表轨迹拼接操作。

1. 切分点选择

切分点t_{split}的选取需要考虑两个因素：

1. 应该是当前策略犹豫不定的位置；
2. 在训练的早期，π_θ能力较弱，那么应该对失败轨迹尽早进行引导。随着训练的进行，逐步引导进入的位置逐渐靠后，直至不再引导。

因此，设计了一种综合考虑上述两个因素的切分点确定机制。

基于熵的局部选择。设轨迹中第t个token的熵为H_t，那么该token被选择的概率为

$$P_{\text{local}}(t)\propto\exp\left(\frac{H_t}{\tau}\right)$$

其中τ是温度系数。熵越高的token，被选择的概率也越高。

基于退火调度的全局选择。构建一个随训练进行，均值从0逐渐增大的正态分布。设在训练进行到第s_{start}步后开始进行引导，直至第s_{end}引导结束。当前的训练步为$s(s_{\text{start}}\leq s\leq s_{\text{send}})$，定义$s'=s-s_{\text{start}}$和$S=s_{\text{end}}-s_{\text{start}}$。那么在当前训练步$s$，前缀占整条轨迹的比例为

$$\alpha(s')=\alpha_{\text{final}}-\frac{1}{2}(\alpha_{\text{final}}-\alpha_{\text{initial}})\left(1+\cos\left(\frac{\pi s'}{S}\right)\right)$$

其中α_{initial}和α_{final}是超参数，代表前缀占整体轨迹的最小比例和最大比例，即$0\leq\alpha_{\text{initial}}<\alpha_{\text{final}}\leq 1$。那么，最终在步骤$s$下，token t被选择的概率服从分布为

$$P_{\text{global}}(t)\propto\mathcal{N}_{\text{trunc}}(t;L\cdot\alpha(s'),\sigma_g^2,1,L)$$

这样离正态分布均值$L\cdot\alpha(s')$越近，则token被选择的概率越高。

最终方案：结合局部和全局的概率分布有

$$P(t_{\text{split}} = t|y) \propto P_{\text{global}}(t) \cdot P_{\text{local}}(t)$$

2. 嵌合轨迹的重要性采样

由于轨迹的前半部分为On-Policy，后半部分是Off-Policy，因此需要一些处理来保证训练稳定性。

$$\rho_{i,t}(\theta) = \begin{cases} \frac{\pi_\theta(y_{i,t}|x,y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x,y_{i,<t})}, & \text{if } t < t_{\text{split}} \\ f\left(\frac{\pi_\theta(y_{i,t}|x,y_{i,<t})}{\pi_{\theta_{\text{e}}}(y_{i,t}|x,y_{i,<t})}\right), & \text{if } t \geq t_{\text{split}} \end{cases}$$

其中$f = \frac{x}{x+\gamma}$。

三、实验结果

基础模型：Qwen2.5-1.5B，引导模型：Qwen2.5-7B-Instruct。

数据集：GSM8K。

评估指标：avg@32。

方法	AMC	MATH	Minera	Olympiad	Avg
GRPO	28.31	58.67	19.92	23.47	32.59
本文方法	33.28	60.90	19.85	24.19	34.55(+1.96)

限于资源的问题，在Qwen2.5-3B上并没有取得正向收益，需要进一步分析。